

Домашнее задание 16 Гареевой Фариды

Интеграция с Apache Kafka

Цель:

изучить интеграцию ClickHouse с Kafka и настроить пайплайн для записи и чтения данных;

Описание/Пошаговая инструкция выполнения домашнего задания:

1. Установите Apache Kafka удобным способом.
2. Установите ClickHouse и выполните необходимые настройки для работы с Kafka.
3. Запишите данные в Kafka и настройте пайплайн чтения через Kafka Engine, затем переместите их в таблицу MergeTree с помощью Materialized View.
4. Проверьте корректность чтения данных из Kafka в ClickHouse.

Полезная ссылка:

https://github.com/AlexeyFerum/teaching_time/wiki/Sbornaya-solyanka#clickhouse--kafka-on-yc

Задания со звездочкой* (необязательно к выполнению):

- Запишите данные в Kafka с помощью ClickHouse Kafka Engine.
- Постройте пайплайн обработки данных без использования Kafka Engine.

На проверку отправьте текстовый документ с описанием выполненных шагов и конфигураций, а также ссылку на репозиторий с кодом и настройками пайплайна.

Удачи при выполнении домашнего задания!

Если у вас возникнут вопросы, их всегда можно задать в чате ДЗ, нажав кнопку ниже, или в учебном Telegram канале группы

Критерии оценки:

Задание считается выполненным, если настроены Kafka и ClickHouse, данные успешно записаны и прочитаны через пайплайн.

Компетенции:

1. Интеграция базы данных с другими системами

- - знать популярные интеграции ClickHouse с другими системами
- - настраивать интеграцию ClickHouse с внешними системами для работы с потоками данных и аналитикой

1. Установите Apache Kafka удобным способом.

Я установила в докере. Запустила вот такой docker-compose.yml. Следует обратить внимание, что все три контейнера: zookeeper, kafka и clickhouse-server-hw13 находятся в одной сети clickhouse_net.

```
version: '3.1'

services:
  zookeeper:
    image: confluentinc/cp-zookeeper:latest
    container_name: zookeeper-server
    environment:
      ZOOKEEPER_CLIENT_PORT: 2181
      ZOOKEEPER_TICK_TIME: 2000
    ports:
      - 22181:2181
    networks:
      - clickhouse_net
  kafka:
    image: confluentinc/cp-kafka:latest
    container_name: kafka-server
    depends_on:
      - zookeeper
    ports:
      - 29092:29092
    environment:
      KAFKA_BROKER_ID: 1
      KAFKA_ZOOKEEPER_CONNECT: zookeeper:2181
      KAFKA_ADVERTISED_LISTENERS:
INTERNAL://kafka:9092,EXTERNAL://localhost:29092
      KAFKA_LISTENER_SECURITY_PROTOCOL_MAP:
INTERNAL:PLAINTEXT,EXTERNAL:PLAINTEXT
      KAFKA_INTER_BROKER_LISTENER_NAME: INTERNAL
      KAFKA_OFFSETS_TOPIC_REPLICATION_FACTOR: 1
    networks:
      - clickhouse_net
  clickhouse-server-hw13:
    image: clickhouse/clickhouse-server:latest
    container_name: clickhouse-server-hw13
    hostname: clickhouse-server-hw13
    ports:
      - "8123:8123" # HTTP порт
      - "9000:9000" # TCP порт
    volumes:
      - clickhouse_data-hw13:/var/lib/clickhouse # Хранение данных
      - clickhouse_config-hw13:/etc/clickhouse-server # Конфигурация
(опционально)
      -
c:\Users\gareeva\OTUS\clickhouse\homework\hw13_storage_policy\clickhouse-
logs:/var/log/clickhouse-server # монтирование локальной директории в
контейнер
      - clickhouse-server-hw13-backup:/etc/clickhouse-backup # конфиги для
clickhouse-backup
    environment:
```

```
CLICKHOUSE_USER: default # Имя пользователя
CLICKHOUSE_PASSWORD: "click1" # Пароль (если требуется)
networks:
  - clickhouse_net
volumes:
  clickhouse data-hw13:
  clickhouse_config-hw13:
  clickhouse-server-hw13-backup:
networks:
  clickhouse_net:
    driver: bridge
```

2. Установите ClickHouse и выполните необходимые настройки для работы с Kafka.

Кликхаус запущен в докере, в предыдущем пункте.

Далее открываем в Windows программу OffsetExplorer,
создаем подключение к localhost:29092
создаем вручную топик hw16_topic

3. Запишите данные в Kafka и настройте пайплайн чтения через Kafka Engine, затем переместите их в таблицу MergeTree с помощью Materialized View.

Далее отправляем сообщение в кафку через OffsetExplorer:

```
{
  "Message": "message1",
  "TimeStamp": "2025-07-06T21:00",
  "ChannelID": "1",
  "Name": "test",
  "Priority": "high"
}
```

Создаем новую БД
create database hw16;

подписываемся на топик кафки

CREATE TABLE hw16.kafka_tbl

```
(
  `Message` String,
  `TimeStamp` String,
  `ChannelID` String,
  `Name` String,
  `Priority` String
)
```

ENGINE = Kafka

SETTINGS

kafka_broker_list = ' kafka:9092',

kafka_topic_list = 'hw16_topic',

kafka_group_name = 'hw16_group',

kafka_format = 'JSONEachRow';

CREATE TABLE hw16.log_target (msg String, income_time String)

```
ENGINE = TinyLog;
```

```
CREATE MATERIALIZED VIEW hw16.kafka_mv TO hw16.log_target  
AS SELECT  
Message AS msg,  
TimeStamp AS income_time  
FROM hw16.kafka_tbl;
```

4. Проверьте корректность чтения данных из Kafka в ClickHouse.

```
select * from hw16.log_target;
```

Результат:

	msg	income_time
1.	message3	2025-07-06T21:00