

Домашнее задание 16 Гареевой Фариды

Загрузка данных в ClickHouse

Цель:

настроить инструмент ETL для загрузки данных в ClickHouse;
создать пайплайн для одноразовой или регулярной загрузки данных из внешнего источника;

Описание/Пошаговая инструкция выполнения домашнего задания:

1. Разверните инструмент для переливки данных (например, Airflow или Airbyte).
2. Разверните ClickHouse.
3. Выберите любой источник данных (API, сервис, БД и пр.).
4. Настройте подключение инструмента к ClickHouse.
5. Постройте пайплайн для переливки данных в ClickHouse с возможностью регулярного или одноразового выполнения.

На проверку отправьте текстовый документ с пошаговыми действиями, конфигурациями и скриншотами успешного выполнения пайплайна. Рекомендуется использовать Git-репозиторий для размещения конфигурационных файлов.

Удачи при выполнении домашнего задания!

Если у вас возникнут вопросы, их всегда можно задать в чате ДЗ, нажав кнопку ниже, или в учебном Telegram канале группы

Критерии оценки:

Задание считается выполненным, если настроен ETL-инструмент, построен пайплайн и данные загружены в ClickHouse.

Компетенции:

1. Интеграция базы данных с другими системами
 - - знать популярные интеграции ClickHouse с другими системами
 - - настраивать интеграцию ClickHouse с внешними системами для работы с потоками данных и аналитикой

1. Разверните инструмент для переливки данных (например, Airflow или Airbyte).

На Windows 11 был локально развернут Airbyte по инструкции

<https://docs.airbyte.com/platform/using-airbyte/getting-started/oss-quickstart#part-2-install-abctl>

```
# Командой получила пароль
abctl local credentials

# Результат работы команды
local airbyte
INFO Credentials:
  Email: gareeva@gnivc.com
  Password: bl6pBAYAJ8CA0KtxZqvD88DFa86yPyQJ
  Client-Id: 44bb8725-9869-4082-9801-c2a46dc1c262
  Client-Secret: TiwslaNTm2QC6xRtjUwX4xmStu6TpyUe
```

2. Разверните ClickHouse.

Был запущен в Docker container. Вот docker-compose.yml

```
version: "3.8"

services:
  clickhouse:
    image: clickhouse/clickhouse-server:latest
    container_name: clickhouse-server-hw16
    ports:
      - "8123:8123" # HTTP-интерфейс (для запросов)
      - "9000:9000" # Native protocol (для клиентов)
    volumes:
      - clickhouse_data-hw16:/var/lib/clickhouse # Сохраняем данные
      - clickhouse_config-hw16:/etc/clickhouse-server # Конфигурация
      (опционально)
      - c:\Users\gareeva\OTUS\clickhouse\homework\hw16_ETL\clickhouse-logs:/var/log/clickhouse-server # монтирование локальной директории в контейнер

    environment:
      - CLICKHOUSE_USER=default
      - CLICKHOUSE_PASSWORD=password

volumes:
  clickhouse_data-hw16: # Том для ClickHouse
  clickhouse_config-hw16:

# Создала новую БД
Create database hw16;
```

3. Выберите любой источник данных (API, сервис, БД и пр.).

В качестве источника использовалась БД PostgreSQL, развернутая в docker container.

```
version: '2'
services:
  postgres:
    image: postgres:15.2
    container_name: postgres_container_slot
    environment:
```

```
POSTGRES_DB: slot_db
POSTGRES_USER: zags
POSTGRES_PASSWORD: zags
ports:
  - "56037:5432"
volumes:
  - pgdata:/var/lib/postgresql/data
volumes:
  slotdata:
```

```
# Создала базу данных
Create database slots_db;

# Создала схему
Create schema integration_slots;

# Создала таблицу
create table integration_slots.work_calendar
(
    work_calendar_id bigint default
nextval('integration_slots.work_calendar_work_calendar_id_seq'::regclass)
not null
    primary key,
    date date
not null,
    day_of_week integer
not null
    constraint check_work_calendar_day_of_week
        check ((day_of_week >= 1) AND (day_of_week <= 7)),
    region_code varchar
not null,
    day_type varchar
not null,
    description varchar
);

comment on table integration_slots.work_calendar is 'Таблица для хранения
рабочего календаря';

comment on column integration_slots.work_calendar.work_calendar_id is
'Уникальный идентификатор строки';

comment on column integration_slots.work_calendar.date is 'Дата календарного
года';

comment on column integration_slots.work_calendar.day_of_week is 'День
недели';

comment on column integration_slots.work_calendar.region_code is 'Код
региона. Всероссийские праздники и рабочие дни отмечаются кодом "ALL".';

comment on column integration_slots.work_calendar.day_type is 'Тип дня';

comment on column integration_slots.work_calendar.description is 'Поле для
наименования праздника';

alter table integration_slots.work_calendar
    owner to zags;

create unique index work_calendar_date_region_code_idx
    on integration_slots.work_calendar (date, region code);

# Создала нового пользователя в Postgres, который может делать select во
всей БД:
```

```
CREATE USER airbyte PASSWORD 'airbyte';
GRANT USAGE ON SCHEMA integration_slots TO airbyte;
GRANT SELECT ON ALL TABLES IN SCHEMA integration_slots TO airbyte;
ALTER DEFAULT PRIVILEGES IN SCHEMA integration_slots GRANT SELECT ON TABLES
TO airbyte;
# Заполнила таблицу данными через созданное ранее java приложение
# Запустила airbyte на localhost:8000, ввела учетные данные почту и пароль
Email: gareeva@gnivc.com
Password: bl6pBAYAJ8CA0KtxZqvD88DFa86yPyQJ
# Выбрала источник Postgres, указала в качестве host host.docker.internal,
port 56036, пользователь airbyte, login airbyte
```

localhost:8000/workspaces/bd2a49ae-198d-4658-afdd-acc1ed179fa0/source/faecc00b-7e7a-4732-b

Sources / Postgres

 **Postgres**
Postgres v3.6.35

Fork

Settings Connections

Source Settings

Source name ⓘ
Postgres

Host ⓘ
host.docker.internal

Port ⓘ
56037

Database Name ⓘ
slot_db

Optional fields

Schemas ⓘ *Optional*
integration_slots x

Username ⓘ
airbyte

Password ⓘ *Optional*
***** Edit

Security

SSL Modes ⓘ

disable

SSH Tunnel Method ⓘ

No Tunnel

Advanced

Update Method ⓘ

☐ Read Changes using Write-Ahead Log (CDC)
Recommended - Incrementally reads new inserts, updates, and deletes using the Postgres [write-ahead log \(WAL\)](#). This needs to be configured on the source database itself. Recommended for tables of any size.

☒ Detect Changes with Xmin System Column
Recommended - Incrementally reads new inserts and updates via Postgres [Xmin system column](#). Suitable for databases that have low transaction pressure.

☐ Scan Changes with User Defined Cursor
Incrementally detects new inserts and updates using the [cursor column](#) chosen when configuring a connection (e.g. created_at, updated_at).

> Optional fields

Test the source

Retest saved source

✔ All connection tests passed!

Delete this source

Copy JSON

Cancel

Test and save

4. Настройте подключение инструмента к ClickHouse.

В airbyte выбран через поиск destination Clickhouse.

В качестве host [host.docker.internal](#)

Port 8123

User default

Password password

Destinations / Clickhouse

Clickhouse

Clickhouse v1.1.0

MARKETPLACE

SettingsConnections

Destination Settings

Marketplace connectors are maintained by the Airbyte community. Airbyte does not offer support SLAs around them, and encourages caution when using them in production. See our [documentation](#) for more details.

Destination name ⓘ

Clickhouse

Host ⓘ

host.docker.internal

Port ⓘ

8123

DB Name ⓘ

hw16

User ⓘ

default

SSH Tunnel Method ⓘ

No Tunnel

Optional fields

Password ⓘ Optional

Edit

JDBC URL Params ⓘ Optional

SSL Connection ⓘ

Raw Table Schema Name ⓘ Optional

Test the destination

Retest saved destination

All connection tests passed!


Delete this destination

Copy JSON


Cancel

Test and save

5. Постройте пайплайн для переливки данных в ClickHouse с
возможностью регулярного или одноразового выполнения.
Создала в airbyte новый connection



Из множества существующих таблиц выбрала working_calendar



По timeline видим, что выгрузка данных реально работает раз в час:

